Institut Supérieur d'Informatique de Mahdia
Année universitaire : 2025-2026 -Semestre : 2

Bsir Bassem

TP N°3

Les réseaux sociaux comme Twitter (X) génèrent des millions de messages par seconde. L'objectif est d'analyser ces données **en temps réel** pour détecter les tendances et sentiments.

Analyse de Tweets en Temps Réel (API réelle + Kafka + Spark)

Objectif pédagogique :

À la fin du TP, vous serez capable de :

- Comprendre le stream processing
- Utiliser Spark Structured Streaming
- Analyser un flux de données en temps réel
- Comparer avec les limites de MapReduce

Fichiers à utiliser :

Architecture du système

Twitter API → Kafka → Spark Streaming → Console / Dashboard

Technologies utilisées :

- Twitter (flux réel)
- Apache Kafka (ingestion)
- Apache Spark (traitement temps réel)

Travail demandé :

Partie 1 : Accès API Twitter (X)

Étape 1 : Créer un accès développeur

https://developer.twitter.com

Créer :

- API Key
- API Secret
- Bearer Token

Étape 2 : Installer les dépendances

```
pip install tweepy kafka-python pyspark
```

Partie 2 : Producteur Kafka (Tweets réels)

Lancer Kafka

Envoyer des tweets réels vers Kafka

collecte tweets → Kafka

Partie 3 : Consumer Spark Streaming

Code Spark (Kafka → Analyse temps réel)

Partie 4 : Traitement avec Spark Streaming

Analyser les tweets en temps réel

Partie 5 : Analyse de sentiment par méthode lexique :

```
positive_words = ["good", "great", "love", "awesome"]
negative_words = ["bad", "hate", "slow", "terrible"]
```

➔ Afficher les résultats temps réel

Explorer des méthodes d'apprentissage supervisé classique (ML) comme alternative à la méthode lexicale simple.